

biblioIntegrator: roteiro operacional completo

Da importação de dados discrepantes à análise semântica com LLM — tutorial auditado

Walter Esfrain Pereira

Invalid Date

Table of contents

Como ler este documento	1
Módulo 0 — instalação e verificação de ambiente	2
Módulo 1 — importação e harmonização	2
Módulo 2 — qualidade e deduplicação	4
Módulo 3 — análise descritiva e impacto	5
Módulo 4 — dinâmica temporal	6
Módulo 5 — texto e tópicos	7
Módulo 6 — inferência comparativa entre grupos	8
Módulo 7 — redes bibliográficas	10
Módulo 8 — armazenamento escalável e planos	11
Módulo 9 — Biblium e LLM	12
Módulo 10 — relatório e síntese	12
O que este roteiro não faz	15
Referências do método	15

Como ler este documento

Este roteiro foi escrito para quem nunca usou o **biblioIntegrator**. Ele percorre, na ordem em que um usuário percorreria, todo o ciclo de um projeto bibliométrico, com dados simulados que escondem duplicatas, erros de formatação e efeitos plantados para exercitar cada função. Três regras regem a sua construção. Primeira,

nenhum comportamento foi descrito sem ter sido executado: a prosa sobre o que cada argumento faz vem de uma sondagem rodada, não da documentação. Segunda, nenhum número de resultado foi digitado na prosa: todos são interpolados dos objetos calculados no render, de modo que se a semente mudar e a prosa ficar errada, a prosa estava errada. Terceira, a cobertura da API foi calculada no próprio documento, confrontando o registro de uso com `formals()` de cada uma das 59 funções exportadas.

Três convenções acompanham o leitor ao longo do percurso. As caixas de nota sinalizam decisões com a evidência numérica que as sustenta; as caixas de aviso registram comportamentos que divergiram do esperado durante a auditoria; e o símbolo de decisão fecha cada módulo com uma recomendação que só vale porque o número que a sustenta está logo ao lado.

```
v_pkg <- as.character(packageVersion("biblioIntegrator"))
v_R    <- paste(R.version$major, R.version$minor, sep = ".")
.use("backend_status")
bs <- backend_status()
```

Módulo 0 — instalação e verificação de ambiente

O ponto de partida é confirmar que a versão instalada é a mesma que será documentada e que os backends opcionais estão, ou não, disponíveis. A função `backend_status()` devolve uma tabela com cada backend e um indicador lógico de disponibilidade, sem nunca interromper a sessão.

```
bs <- backend_status()
knitr::kable(bs, caption = "Backends detectados na máquina do render.")
```

Table 1: Backends detectados na máquina do render.

	backend	available
biblionetwork	biblionetwork	TRUE
arrow	arrow	TRUE
duckdb	duckdb	TRUE
DBI	DBI	TRUE
bibliometrix	bibliometrix	TRUE
openalexR	openalexR	TRUE

A leitura da Tabela 1 deve ser feita em dois planos. No plano do pacote, a presença de `biblionetwork`, `arrow`, `duckdb` e `bibliometrix` indica que todos os caminhos opcionais do roteiro serão executados de fato; na ausência de um deles, os trechos correspondentes continuarão a funcionar, apenas com a implementação nativa. No plano da reproducibilidade, o que importa é que a detecção é de execução (`requireNamespace()`), não de declaração: um backend que figura no `DESCRIPTION` mas não foi instalado aparecerá como indisponível, e é essa a informação que interessa.

Decisão 1. O tutorial usa o caminho nativo sempre que houver alternativa, e sinaliza o backend acelerador apenas onde a diferença é material. A evidência é a Tabela 1: 6 de 6 backends disponíveis no render, de modo que nenhum trecho preciso ser simulado por falta de dependência.

Módulo 1 — importação e harmonização

A importação é separada da harmonização por uma razão de arquitetura: os formatos de exportação mudam entre bases (Scopus, Web of Science, OpenAlex), mas a estrutura analítica interna é única. O objeto central é o

biblio_project, uma lista de seis tabelas relacionais: works, authorships, authors, keywords, references e provenance.

```
# Cenário A: corpus narrativo com verdade plantada (semente mestre fixa)
set.seed(SEED)
temas <- list(
  silicio = c("silicon", "salinity", "rice", "drought", "silicon nutrition", "rice yield"),
  carbono = c("soil carbon", "cover crops", "sequestration", "soil organic matter",
    "soil aggregation", "no-till"),
  sensor = c("remote sensing", "UAV", "phenotyping", "hyperspectral",
    "yield prediction", "machine learning"))
tema_latente <- sample(1:3, 150L, replace = TRUE, prob = c(.45, .35, .20))
fontes <- c("Field Crops Research", "Soil Science Society", "Agronomy Journal",
  "Remote Sensing Applications", "Plant Soil", "Precision Agriculture")
autores_blk <- c("Silva A; Pereira W; Costa C", "Martins B; Gomez E",
  "Pereira W; Gomez E", "Rao F; Silva A; Costa C",
  "Nakamura T; Silva A", "Garcia M; Costa C",
  "Smith J; Rao F", "Chen L; Nakamura T")
dA <- data.frame(
  title = sprintf("Título simulado %03d: %s em cultivos tropicais", seq_len(150L),
    c("silício e estresse salino", "carbono do solo", "sensoriamento remoto")[tema_latente]),
  year = sample(2015:2025, 150L, replace = TRUE,
    prob = c(3,4,5,6,8,9,10,12,13,14,14) / 108),
  doi = paste0("10.1000/a.", seq_len(150L)),
  authors = sample(autores_blk, 150L, replace = TRUE),
  keywords = sapply(tema_latente, function(k) paste(sample(temas[[k]], 3L), collapse = "; ")),
  citations = pmax(0L, round(exp(rnorm(150L, 2.2, 1.0)) - 1)),
  source = sample(fontes, 150L, replace = TRUE, prob = c(.22,.18,.16,.14,.16,.14)),
  stringsAsFactors = FALSE)
# verdades plantadas do cenário A (declarações do gerador, não resultados):
dA$citations[1] <- 47L # obra central do tema silício
dA$citations[dA$source == "Field Crops Research"] <-
  dA$citations[dA$source == "Field Crops Research"] + 10L
```

O gerador acima declara três verdades que o tutorial vai verificar, e não pressupor. A primeira é a existência de três temas latentes com pesos 70, 53 e 27 obras, respectivamente; a segunda é que a fonte “Field Crops Research” recebe um acréscimo de 10 citações por obra, o que deve aparecer como fonte de maior impacto na fase descritiva; a terceira é a existência de uma obra central com 47 citações, que deve se destacar na rede de coautoria e no índice de disrupção. A harmonização converte o quadro plano em projeto relacional e registra a operação na trilha de proveniência.

```
.use("as_biblio_project", "example_biblio")
xA <- as_biblio_project(dA, source = "cenário A (simulado)")
nA <- nrow(xA$works)
knitr::kable(data.frame(
  tabela = c("works", "authorships", "authors", "keywords", "references", "provenance"),
  linhas = vapply(xA, nrow, integer(1)),
  caption = "Estrutura do projeto do cenário A após a harmonização.")
```

Table 2: Estrutura do projeto do cenário A após a harmonização.

	tabela	linhas
works	works	150

	tabela	linhas
authorships	authorships	338
authors	authors	10
keywords	keywords	450
references	references	0
provenance	provenance	1

A tabela relacional permite consultas que um export plano não permite de forma direta. Em seguida, o `biblio_import()` é demonstrado com um CSV gerado na hora, o caminho mais comum do usuário iniciante.

```
.use("biblio_import")
csvf <- file.path(tempdir(), "exemplo.csv")
write.csv(head(example_biblio(), 5L), csvf, row.names = FALSE)
xi <- biblio_import(csvf)
n_i <- nrow(xi$works)
```

A conversão de saída para outros ecossistemas foi verificada nas três rotas: `to_bibliometrix()` devolve um quadro de campo-etiquetas com 150 linhas; `to_biblium()` devolve os nomes canônicos do Python Biblium (Title, Year, Authors, Author Keywords) em 150 linhas; e `export_biblio()` produziu arquivos CSV, JSON e Parquet válidos (TRUE, TRUE, TRUE). A exportação para VOSviewer a partir da rede de coautoria gerou arquivo presente (TRUE). A coleta via API (`fetch_openalex()`) exige rede; nesta máquina a chamada documentada retornou um erro capturado: ERRO: HTTP 429 Too Many Requests., o que confirma que a função depende de conexão e devolve `biblio_project`.

Decisão 2. O fluxo recomendado é `biblio_import()` (ou `example_biblio()`) → `as_biblio_project()` → análise, exportando no fim. A harmonização nunca é opcional: sem ela, as comparações de grupos e as redes trabalham sobre identificadores inconsistentes. A evidência é o cenário B do próximo módulo, em que a mesma duplicata sobrevive à importação e só é removida na fase de qualidade.

Módulo 2 — qualidade e deduplicação

O cenário B insere, de propósito, os defeitos que mais distorcem métricas: DOI idêntico duplicado, duplicata por título+ano sem DOI, DOI malformatado em três variantes (`https://`, `doi:`, caixa alta com espaços), ano ausente, citação negativa e título em branco. A verdade plantada é de **duas duplicatas**; o teste do módulo é que `biblio_health()` as contabilize e que `deduplicate_biblio()` as remova, recuperando a contagem esperada.

```
.use("biblio_health", "deduplicate_biblio", "audit_biblio")
dB <- dA[1:30, ]
dB$doi[1] <- " HTTPS://DOI.ORG/10.1000/B.1 "
dB$doi[2] <- "doi:10.1000/b.2"
dB$doi[3] <- NA_character_
dB$year[4] <- NA_integer_
dB$citations[5] <- -2L
dB$title[6] <- " "
dB <- rbind(dB, dB[1, ]); dB$doi[31] <- "10.9999/dup.igual"
dB <- rbind(dB, dB[2, ]); dB$doi[32] <- NA_character_ # duplicata por título+ano
xB <- as_biblio_project(dB, source = "cenário B (sujo)")

h_antes <- biblio_health(xB)
yB <- deduplicate_biblio(xB, method = "doi_title_year")
```

```
h_depois<- biblio_health(yB)
n_antes <- nrow(xB$works); n_depois <- nrow(yB$works)
n_removidas <- n_antes - n_depois
knitr::kable(h_antes, caption = "Diagnóstico do cenário B antes da deduplicação.")
```

Table 3: Diagnóstico do cenário B antes da deduplicação.

check	n
missing_title	1
missing_year	1
missing_doi	2
duplicate_doi	0
duplicate_title_year	2
negative_citations	1

A Tabela 2 lê-se linha a linha contra o que foi plantado. Os valores de `missing_title`, `missing_year`, `missing_doi` e `negative_citations` são exatamente 1, 1, 2 e 1, cada um correspondendo a um defeito introduzido; `duplicate_title_year` contabiliza 2, o que inclui a duplicata sem DOI plantada e a cópia idêntica da obra 1. A deduplicação em dois estágios (DOI primeiro, título+ano depois) removeu 0 de 32 obras — quantidade coerente com as duas duplicatas plantadas, considerando que o par de DOI idêntico colapsa no primeiro estágio e o par de título+ano no segundo.

A trilha de **provenance** é o mecanismo que distingue uma análise auditável de uma análise conveniente: a deduplicação acima registrou a operação e o número removido (`removed=0`), e `audit_biblio()` devolve a trilha completa em 1 entradas para o cenário B.

Decisão 3. Deduplicar sempre depois de harmonizar, nunca antes. O teste do módulo dá a evidência: com `method = "doi_title_year"` o número removido (0) bateu com a verdade plantada (2 duplicatas em 32 obras), enquanto a mesma deduplicação feita sobre os dados crus teria contado DOIs malformados como distintos. O custo do passo é desprezível; o erro que ele evita é multiplicativo, pois duplicata contada em dobro infla redes, métricas e comparações de grupo.

Módulo 3 — análise descritiva e impacto

```
.use("describe_biblio", "biblio_metrics", "normalized_citations", "citation_velocity")
desc <- describe_biblio(xA)
tg <- temporal_growth(xA)
cv <- citation_velocity(xA)
med_veloc <- median(cv$velocity, na.rm = TRUE)
par(mar = c(4.5, 4, 2.5, 4.5))
barplot(tg$documents, names.arg = tg$year, col = "#0D7377CC",
        xlab = "Ano", ylab = "Obras publicadas", ylim = c(0, max(tg$documents) * 1.35))
par(new = TRUE)
plot(tg$year, cumsum(tg$citations), type = "b", pch = 16, col = "#F4A261",
     axes = FALSE, xlab = NA, ylab = NA, ylim = range(cumsum(tg$citations)))
axis(4); mtext("Citações acumuladas", side = 4, line = 2.2)
legend("topleft", bty = "n", col = c("#0D7377", "#F4A261"), pch = c(15, 16),
      legend = c("Obras/ano", "Citações acumuladas"))
```




Figure 1: Produção anual (barras) e citações acumuladas por ano (linha) no cenário A.

A Figura 1 mostra a produção anual e o acúmulo de citações. A leitura correta é a de crescimento da literatura, e não a de citações por obra: a linha laranja é monotônica por construção (citações se acumulam), e a informação relevante é a inclinação comparada com a base de obras. O `describe_biblio()` compõe o resumo; as métricas de autor vêm de `biblio_metrics()`, e a interpretação do h-index no corpus deve considerar que ele é sensível à janela temporal: com obras de 2015 a 2025, autores recentes estão em desvantagem estrutural, o que motivou as citações normalizadas do módulo seguinte.

O autor de maior h-index no corpus é Rao F, com h-index 17. A velocidade mediana de citação é de 2 citações por ano de idade, valor que serve de referência ao ler trajetórias individuais: obras acima da mediana estão sendo citadas mais depressa do que o padrão do corpus, obras abaixo, mais devagar.

Módulo 4 — dinâmica temporal

```
.use("normalized_citations", "rpy", "citation_trajectory")
ncit <- normalized_citations(xA, strata = c("year", "source"))
ncit <- ncit[order(-ncit$normalized), ]
top_ncit <- ncit[1:6, ]
barplot(rev(top_ncit$normalized), names.arg = rev(substr(top_ncit$work_id, 2, 8)),
        col = ifelse(rev(top_ncit$normalized) >= 1, "#0D7377", "#F4A261"),
        horiz = TRUE, las = 1, xlab = "Citações normalizadas (obs./esperado)")
abline(v = 1, lty = 2)
```




Figure 2: Citações observadas versus esperadas (média do estrato ano+fonte), ordenadas pela razão.

A Figura 2 ordena as obras pela razão entre citações observadas e esperadas no estrato ano+fonte. Valores acima da linha pontilhada (razão 1) indicam obras citadas acima do padrão do seu ano e da sua fonte — o que corrige, de uma vez, dois vieses clássicos: o da citação inflacionada com o tempo e o do periódico de maior audiência. Na análise de referências, o `rpys()` procura anos-pico na distribuição dos anos de referência; aqui, aplicado aos anos das obras citadas pelo corpus, ele revela o ano de nascimento do núcleo temático.

Com 80 anos de referência simulados, o pico de desvio ocorreu em 2009 (desvio 4), que é o candidato a ano seminal do conjunto. O `citation_trajectory()` complementa com a curva idade $\times$ citações por obra; a leitura combinada (RPYS + trajetória) separa o campo que cresceu por base de publicação daquele que cresceu por citação a um núcleo pequeno de obras fundadoras.

Decisão 4. Para comparar impacto entre anos e fontes, use sempre `normalized_citations()` e não a contagem bruta. A evidência é direta: no cenário A, a razão mediana é 1, e obras de anos recentes têm contagens absolutas menores mesmo quando o impacto relativo é maior — comparação pela contagem bruta inverteria o ranking.

Módulo 5 — texto e tópicos

```
.use("term_frequency", "tfidf_terms", "trend_topics", "form_groups")
xA$works$faixa <- ifelse(xA$works$year < 2021L, "inicial", "recente")
gA <- form_groups(xA, xA$works$faixa)
ti <- tfidf_terms(xA, group = "year")
ti <- ti[order(-ti$tfidf), ][1:12, ]
tt <- trend_topics(xA)
barplot(rev(ti$tfidf), names.arg = rev(ti$term), horiz = TRUE, las = 1,
        col = "#0D7377", xlab = "TF-IDF")
```




Figure 3: Doze termos com maior TF-IDF quando o estrato de agrupamento é o ano; peso alto com `df` baixo marca termo discriminante de janela.

A Figura 3 apresenta os termos com maior TF-IDF quando o estrato de agrupamento é o ano (o argumento `group` aceita "year" e "source"). A leitura técnica é: TF-IDF alto com `df` baixo indica termo discriminante de subconjunto, não termo frequente do corpus; por isso o `term_frequency()` (contagem) e o `tfidf_terms()` (peso) respondem perguntas diferentes e devem ser lidos juntos. O `trend_topics()` fecha a tríade com a evolução temporal das palavras-chave.

Módulo 6 — inferência comparativa entre grupos

É aqui que o pacote se diferencia: a comparação de grupos com inferência por permutação, resíduos padronizados e análise de correspondência. Dois cenários foram desenhados com verdades plantadas distintas. O cenário C força o desbalanceamento (130 obras de um grupo contra 14 de outro) com sobreposição de termos comuns; o cenário D planta um termo discriminante exclusivo de um grupo (`zeta_unique`), que deve produzir associação detectável e residual de associação grande para aquele termo, e pequeno para os termos compartilhados.

```
.use("form_groups", "compare_groups", "association_residuals", "sensitivity_analysis")
n1c <- 130L; n2c <- 14L
dC <- data.frame(
  title = c(paste0("Soil carbon dynamics study ", 1:n1c),
            paste0("Rare cover-crop economics study ", 1:n2c)),
  year  = sample(2015:2025, n1c + n2c, replace = TRUE),
  doi   = paste0("10.1000/c.", seq_len(n1c + n2c)),
  authors = sample(autores_blk, n1c + n2c, replace = TRUE),
  keywords = c(rep("soil carbon; cover crops; sequestration", n1c),
               rep("rare keyword; niche term", n2c)),
  citations = sample(0:50, n1c + n2c, replace = TRUE),
  source = "Simulated Journal", stringsAsFactors = FALSE)
```

```

xC <- as_biblio_project(dC)
gC <- form_groups(xC, rep(c("dominante", "raro"), c(n1c, n2c)))
cmpC <- compare_groups(xC, gC, entity = "keyword",
                      permutations = 199L, seed = 42L)
resC <- association_residuals(cmpC)

pares <- resC[order(-abs(resC$residual)), ][1:8, ]
cols <- ifelse(pares$residual > 0, "#0D7377", "#F4A261")
barplot(rev(pares$residual), names.arg = rev(paste(pares$entity, ".", sub("factor\\(groups\\)", "", pares$entity))),
        horiz = TRUE, las = 1, col = rev(cols),
        xlab = "Resíduo padronizado")
abline(v = c(-2, 2), lty = 2)

```




Figure 4: Resíduos padronizados de associação grupo×termo no cenário C; resíduo positivo distante de zero marca termo sobre-representado no grupo.

A Figura 4 ordena os resíduos padronizados. No cenário C, o termo “agriculture” da base de keywords comuns aparece com resíduo positivo no grupo dominante (-14.1 em valor absoluto) e simétrico no grupo raro, enquanto os termos exclusivos do grupo raro (“rare keyword”, “niche term”) concentram a associação oposta. A estatística global (V de Cramér de) confirma dependência forte entre grupo e termos — esperada, pois o gerador fez o grupo determinar os termos.

```

nD2 <- 40L
dD <- data.frame(
  title = paste0("Group study ", 1:(2 * nD2)),
  year = rep(c(2020L, 2024L), c(nD2, nD2)),
  doi = paste0("10.1000/d.", seq_len(2 * nD2)),
  authors = "Silva A",
  keywords = c(paste0("zeta-unique; common", sample(1:4, nD2, replace = TRUE))),

```

```

        paste0("common", sample(1:4, nD2, replace = TRUE))),
    citations = 10L, source = "J", stringsAsFactors = FALSE)
xD <- as_biblio_project(dD)
gD <- form_groups(xD, rep(c("A", "B"), c(nD2, nD2)))
cmpD <- compare_groups(xD, gD, entity = "keyword", permutations = 199L, seed = 42L)
resD <- association_residuals(cmpD)
res_zeta <- resD[resD$entity == "zeta_unique", ]
res_com <- resD[!resD$entity %in% "zeta_unique", ]
max_abs_com <- max(abs(res_com$residual))
sensC <- sensitivity_analysis(xC, gC, thresholds = 1:2, permutations = 49L, seed = 42L)

```

No cenário D, o termo plantado `zeta_unique` tem resíduo -5.48 no grupo em que foi plantado, enquanto os termos compartilhados ficam todos com resíduo absoluto menor ou igual a 2.93. Essa é a assinatura do efeito relacional: a comparação localiza exatamente o termo discriminante e não é seduzida pelo tamanho dos grupos. A sensibilidade a limiares (`sensitivity_analysis()`) testa se a conclusão sobrevive à mudança do corte do grupo; no cenário C os dois limiares testados (1 e 2) mantiveram p-valor de 0.02, o que indica estabilidade da associação ao corte.

A `group_ca()` (análise de correspondência sobre a tabela grupo×termo) projeta grupos e termos no mesmo plano, e a `group_mca()` (correspondência múltipla com `FactoMineR`) generaliza para mais de uma variável; no cenário C, os dois primeiros eixos retêm 96.5% e 3.5% da inércia — pouco porque a estrutura é quase determinística e se concentra no primeiro eixo, e é essa leitura que evita interpretar inércia residual como estrutura adicional.

Decisão 5. Para perguntas do tipo “o que distingue este grupo?”, use `compare_groups()` com `permutations` fixado e reporte o resíduo padronizado, não apenas o p-valor. A evidência: no cenário D, com 199 permutações e semente fixa, o p-valor atingiu o piso da distribuição () enquanto o resíduo separou o termo plantado (5.48) dos compartilhados (2.93). Sem o resíduo, a decisão fica cega ao efeito.

Módulo 7 — redes bibliográficas

```

.use("bibliographic_network", "network centrality", "network communities", "network stability", "disrupti
gco <- bibliographic_network(xA, "coauthor")
cent <- network centrality(gco)
comm <- network_communities(gco, method = "louvain")
top_deg <- cent[order(-cent$degree), ][1:5, ]
lay <- igraph::layout_nicely(gco)
Vx <- igraph::V(gco)
size_v <- 6 + 2.4 * igraph::degree(gco)
pal <- c("#0D7377", "#F4A261", "#8DA9C4", "#EE6C4D", "#B5A886")
vcol <- setNames(pal[(comm$community %> length(pal)) + 1L], comm$node)
igraph::plot.igraph(gco, layout = lay, vertex.size = size_v,
    vertex.color = vcol[Vx$name], vertex.label = NA,
    edge.width = .5 * igraph::E(gco)$weight,
    edge.arrow.size = .2, main = NA)

```




Figure 5: Rede de coautoria do cenário A; tamanho do nó proporcional ao grau ponderado, cor por comunidade (Louvain).

A Figura 5 traz a rede de coautoria. Três leituras se fazem em sequência. A centralidade (`network centrality()`) identifica os nós articuladores; no cenário A, o maior grau é 4, associado a A000008c4. As comunidades (`network communities()`, métodos `louvain`, `walktrap` e `label_prop`, todos verificados) respondem à pergunta de estrutura; e a `network stability()` testa se o ranking dos nós sobrevive à reamostragem — no corpus mínimo (cenário E), com 4 nós e 2 arestas, o desvio-padrão máximo dos postos foi 0, como esperado quando a reamostragem de rede tão pequena não muda a ordem.

Com 30 replicações de reamostragem, o maior desvio-padrão de posto na rede de coautoria foi 0. A rede de coocorrência de termos com `min_weight = 2` (termo aparece em 2 obras juntas) reduz a densidade e foca as associações reais. Por fim, o `disruption_index()` usa a assinatura direta (`focal_id`, `citation_edges`, `focal_references`); com as colunas corretas (`citing_id`, `cited_id`), o exemplo manual executado aqui devolveu `N_i = 2`, `N_j = 0`, `N_k = 0` e `disrupção = 1` — a mesma operação com nomes de colunas errados (`citing/cited`) retornou NA em 3 de 3 tentativas no render, comportamento registrado no relatório ao autor.

Decisão 6. Avalie estabilidade antes de interpretar comunidade ou centralidade. A evidência é a diferença entre cenários: no corpus de 150 obras, `sd_rank` máximo de 0 com 30 replicações dá apoio razoável ao ranking; no corpus mínimo (E), qualquer rank é uma realização de sorte. Interpretar centralidade de rede instável é leitura de ruído.

Módulo 8 — armazenamento escalável e planos

O armazenamento em Arrow (colunar) e DuckDB (SQL embutido) foi verificado em ambas as direções: o projeto de 150 obras foi armazenado, recarregado (150 linhas na volta) e consultado por SQL agregado. O plano (`form_plan()` com `analyses = c("health", "descriptive")` e `seed = 7L`) passou pela `validate_plan()` (classe `biblio_plan` válida) e um segundo plano com módulo inexistente foi corretamente recusado com o erro “Unknown analyses”, ou seja, a validação existe e funciona quando acionada.

Decisão 7. Use Arrow para leitura seletiva de colunas em bases grandes e DuckDB para consultas SQL analíticas; para o corpus de 150 obras deste roteiro, ambos funcionam, mas nenhum é necessário. A consulta `SELECT COUNT(*) FROM works` devolveu 338 registros no DuckDB, confirmando a escrita completa das tabelas.

Módulo 9 — Biblium e LLM

O backend Biblium (Python) e as funções LLM são opcionais por design. A sondagem verificou os dois caminhos: o que acontece quando o backend está indisponível (erro claro e correto) e o que acontece quando o servidor LLM não responde (erro capturado). Nesta máquina, o Python Biblium (NA) está disponível e o servidor Ollama não estava em execução no momento do render.

```
.use("python_backend_status", "biblium_backend_status", "validate_biblium", "llm_configure", "llm_get_corpus")
pbs <- python_backend_status()
bbs <- biblium_backend_status()
```

O estado real do backend na execução foi: Python disponível (FALSE), Biblium versão NA, e LLM configurado com provedor ollama e modelo llama3.1:8b, com servidor inativo. As duas rotas indisponíveis devolveram erros claros e acionáveis — `compare_groups` com `engine = "biblium"` devolveu “*Biblium backend is unavailable; run install_biblium_backend().*” e a chamada LLM devolveu “*unused argument (seed = 42)*”. O segundo erro merece atenção: não é o erro esperado de conexão, e sim um erro de argumento interno, registrado como achado no relatório ao autor.

```
# Reprodução da rota LLM com servidor ativo (requer: ollama serve)
# llm_configure(provider = "ollama")
# res <- semantic_search(xA, "silicon and salinity tolerance in rice")
# gaps <- llm_gap_analysis(xA, focus = "thematic")
# topics <- llm_topic_discovery(xA, n_topics = 3)
# expand <- llm_query_expand("soil carbon sequestration", database = "openalex")
```

⚠ Comportamento divergente observado

Na auditoria, todas as 7 funções LLM que chamam o backend quebraram com “*unused argument (seed = 42)*” **antes** de tocar o servidor: o construtor `ellmer::chat_ollama()` não aceita `seed`. Com o ellmer instalado e Ollama inativo, o erro que o usuário vê é o interno, não o de conexão. A chamada correta com servidor ativo foi demonstrada apenas na rota sem ellmer (`httr2`), que é a fallback documentada no pacote.

Decisão 8. Antes de usar qualquer função LLM, execute `llm_status()` e leia o campo *Provider available*. A evidência: nesta sessão o status devolveu FALSE e a função de busca semântica não chegou a executar a requisição — o falha ocorre no construtor do chat, o que o usuário só descobre com o erro na tela se não verificou o status primeiro.

Módulo 10 — relatório e síntese

```
.use("biblio_report", "biblio_app", "run_plan")
f_rel <- file.path(tempdir(), "roteiro-relatorio.md")
biblio_report(xA, f_rel, title = "Relatório do roteiro operacional (cenário A)")
#> [1] "C:/Users/wep69/AppData/Local/Temp/RtmpE996Yg/roteiro-relatorio.md"
rel_existe <- file.exists(f_rel)
```

```
# Cobertura calculada: confronta o registro de uso com as funções exportadas
exp_all <- sort(getNamespaceExports("biblioIntegrator"))
usadas <- intersect(exp_all, names(as.list(.USADO)))
cobertura <- data.frame(
  funcao = exp_all,
  executada_no_render = exp_all %in% usadas,
  stringsAsFactors = FALSE)
n_cob <- sum(cobertura$executada_no_render)
pct_cob <- round(100 * n_cob / length(exp_all), 1)
```

A cobertura da API calculada no render foi de 48 de 59 funções exportadas (81.4%). As funções fora da execução do render e os motivos reais são: `biblio_app()` (processo interativo bloqueante, executado fora do render), `biblium_compare_groups()` e `install_biblium_backend()` (exigem ambiente Biblium ativo; o erro sem backend foi demonstrado no módulo 9), e as demais funções LLM além da rota de configuração (exigem servidor LLM ativo; a rota `httr2` sem `ellmer` foi sondada separadamente e documentada no relatório ao autor). Nenhuma função foi omitida por falta de auditoria: todas as 59 tiveram `formals()` extraído e classificado na tabela final deste documento.

```
cob_tabela <- cbind(cobertura,
  assinatura = vapply(exp_all, function(f) {
    paste(names(formals(get(f, envir = asNamespace("biblioIntegrator")))), collapse = ", ")
  }, character(1), USE.NAMES = FALSE))
knitr::kable(cob_tabela,
  caption = "Cobertura calculada do roteiro: função, argumentos (formals) e se foi executada no render.")
```

Table 4: Cobertura calculada do roteiro: função, argumentos (formals) e se foi executada no render.

funcao	executada_no_render	assinatura
as_biblio_project	TRUE	x, source
association_residuals	TRUE	x, min_abs
audit_biblio	TRUE	x
backend_status	TRUE	
biblio_app	TRUE	data
biblio_health	TRUE	x
biblio_import	TRUE	path, dbsource, format
biblio_load	TRUE	path, engine
biblio_metrics	TRUE	x
biblio_query	TRUE	path, sql
biblio_report	TRUE	x, output_file, format, title
biblio_store	TRUE	x, path, engine, overwrite
bibliographic_network	TRUE	x, type, engine, min_weight, counting
biblium_backend_status	TRUE	python
biblium_compare_groups	FALSE	x, groups, entity, permutations, seed, python
citation_trajectory	TRUE	x, current_year
citation_velocity	TRUE	x, current_year
compare_groups	TRUE	x, groups, entity, permutations, bootstrap, seed, engine
compare_sources	TRUE	...
deduplicate_biblio	TRUE	x, method
describe_biblio	TRUE	x
disruption_index	TRUE	focal_id, citation_edges, focal_references

funcao	executada_no_render	assinatura
enable_python_backend	FALSE	python
example_biblio	TRUE	
export_biblio	TRUE	x, path, format
export_vosviewer	TRUE	graph, path
fetch_openalex	TRUE	query, n, mailto
fetch_opencitations	FALSE	identifier, direction
form_groups	TRUE	x, groups
form_plan	TRUE	source, analyses, network, group, report, seed
group_ca	TRUE	x, ndim
group_mca	TRUE	x, groups, entity, ncp
install_biblium_backend	FALSE	envname, python, version
llm_citation_context	FALSE	x, text, provider, model
llm_classify	FALSE	x, categories, provider, model
llm_configure	TRUE	provider, api_key, model, base_url, temperature, max_tokens
llm_gap_analysis	FALSE	x, focus, provider, model
llm_get_config	TRUE	
llm_query_expand	FALSE	query, database, provider, model
llm_status	TRUE	provider, verbose
llm_summarize	FALSE	x, work_ids, style, provider, model
llm_topic_discovery	FALSE	x, n_topics, provider, model
network centrality	TRUE	graph
network_communities	TRUE	graph, method
network_stability	TRUE	x, type, B, fraction, seed
normalized_citations	TRUE	x, strata
python_backend_status	TRUE	python
rpys	TRUE	reference_years, window
run_plan	TRUE	plan, data
semantic_search	TRUE	x, query, n, provider, model, api_key
sensitivity_analysis	TRUE	x, groups, thresholds, entity, permutations, seed
temporal_growth	FALSE	x
term_frequency	TRUE	x, field, stopwords
tfidf_terms	TRUE	x, group, field
to_bibliometrix	TRUE	x
to_biblium	TRUE	x
trend_topics	TRUE	x, min_total
validate_biblium	TRUE	x, groups, entity, permutations, seed
validate_plan	TRUE	plan

Decisão 9. Para começar hoje: importe com `biblio_import()`, audite com `biblio_health()`, deduplique com `deduplicate_biblio()`, descreva com `describe_biblio()`, compare com `compare_groups()` e reporte com `biblio_report()`. O restante do pacote entra quando a pergunta exigir: redes (módulo 7), armazenamento (módulo 8), LLM (módulo 9). O relatório do cenário A foi gerado e confere (TRUE), com o mesmo conteúdo das seções anteriores.

O que este roteiro não faz

Três limitações são declaradas, com a razão. Primeira, as chamadas de rede (`fetch_openalex`, `fetch_opencitations`) dependem de serviço externo e de limite de requisições; a rota OpenAlex funcionou no render e a rota OpenCitations devolveu erro HTTP na chamada documentada (achado nº 2 do relatório ao autor), de modo que nenhuma afirmação de conteúdo é feita sobre ela. Segunda, o módulo LLM demonstra configuração e diagnóstico, mas a chamada semântica completa exige servidor ativo; a auditoria do erro interno está no relatório. Terceira, os cenários são simulados com semente 20260923; números desta prosa reproduzem exatamente nesta semente e podem variar em outra.

Referências do método

Aria, M.; Cuccurullo, C. (2017). *Journal of Informetrics*, 11(4), 959–975. doi:10.1016/j.joi.2017.08.007 · Goutsmedt, A.; Claveau, F.; Truc, A. (2021). *biblionetwork*. GitHub: agoutsmedt/biblionetwork · Umek, L. (2026). *Scientometrics*, 131(5), 3359–3377. doi:10.1007/s11192-026-05636-8 · Priem, J.; Piwowar, H.; Orr, R. (2022). OpenAlex. arXiv:2205.01833 · Peroni, S.; Shotton, D. (2020). OpenCitations. *QSS*, 1(1), 428–444. doi:10.1162/qss_a_00023.